

Análisis exploratorio de datos de juegos de mesa

Memoria técnica final

Proyecto: Tabletop-games-EDA

Fuente principal: BoardGameGeek y tablas auxiliares de categorías, mecánicas, diseñadores y artistas.

Este PDF presenta la memoria técnica final, con metodología, resultados y visualizaciones generadas a partir de los datos del repositorio.

Índice

1. Introducción y contexto
2. Hipótesis de trabajo
3. Fuentes de datos
4. Preprocesado y limpieza
5. Metodología de análisis
6. Resultados principales
7. Visualizaciones y resultados comparativos
8. Verificación de hipótesis
9. Conclusiones y próximos pasos
10. Anexos y referencias

Hipótesis de trabajo

1. La mayor parte de los juegos estará pensada para grupos pequeños, especialmente entre 2 y 4 jugadores, con duraciones medias cortas o moderadas.
2. Los juegos mejor valorados tenderán a presentar una complejidad mayor (weight) y una duración más larga que el promedio.
3. La popularidad medida por interest = owned + wishing + wanting no coincidirá exactamente con el ranking oficial.
4. Las variables de complejidad, duración y valoración formarán un patrón multivariante reconocible, aunque no perfectamente lineal.

Metodología y análisis

1. Revisión de cardinalidad y valores nulos para decidir qué variables eran válidas para el EDA.
2. Conversión a numérico de campos críticos, especialmente rank_boardgame, playingtime, weight y variables de interés.
3. Estadística descriptiva: media, mediana, desviación estándar y skew para las variables numéricas principales.
4. Visualización: histogramas con KDE, boxplots y gráficos de barras para entender distribuciones y frecuencias.
5. Segmentación: comparación entre el top100 por ranking y el top100 por interés (owned + wishing + wanting).
6. Cruzado de tablas por row_id para asociar juegos con categorías, mecánicas, diseñadores y artistas.

Resultados principales

min_players: n=28462, media=1.94, mediana=2.00, std=0.69, min=0.0, max=9.0, skew=1.32

max_players: n=28462, media=4.70, mediana=4.00, std=2.55, min=0.0, max=30.0, skew=2.71

playingtime: n=28462, media=75.27, mediana=45.00, std=102.59, min=1.0, max=1200.0, skew=5.33

minimum_age: n=28462, media=9.84, mediana=10.00, std=3.51, min=0.0, max=21.0, skew=-0.77

weight: n=28462, media=1.98, mediana=1.93, std=0.78, min=1.0, max=4.8, skew=0.69

Las medianas de min_players y max_players (2 y 4) muestran que gran parte de los juegos están pensados para grupos pequeños.

playingtime presenta una distribución muy sesgada a la derecha, con muchos títulos cortos y una cola larga de duraciones elevadas.

minimum_age se sitúa alrededor de 10 años y weight se mantiene en un nivel moderado, lo que apunta a una muestra accesible en términos generales.

weight y playingtime presentan una correlación positiva moderada-alta (0.533), por lo que los juegos más complejos suelen durar más.

average_rating y weight también muestran una relación positiva relevante (0.519).

rank_boardgame se relaciona de forma negativa con average_rating (-0.720) y con weight (-0.405), coherente con la lógica del ranking.

average_rating y playingtime mantienen una asociación positiva (0.270), aunque menos intensa que la observada con weight.

El pairplot y la matriz de correlaciones muestran que la valoración, la duración y la complejidad se mueven de forma conjunta.

bayes_average mantiene una asociación fuerte con interest (0.676), reflejando una noción parecida de atracción o recepción del juego.

release_year muestra correlaciones débiles con el resto de variables, por lo que no actúa como factor dominante en esta muestra.

Frecuencias globales

Top categorías globales: Card Game, Expansion for Base-game, Fantasy, Wargame y Fighting encabezan el dataset.

Top mecánicas globales: Dice Rolling, Hand Management y Variable Player Powers son las más frecuentes.

Top diseñadores globales: Reiner Knizia, Eric M. Lang, Nate French y Steve Jackson aparecen con mayor recurrencia.

Top artistas globales: Rodger B. MacGowan, Franz Vohwinkel y Michael Menzel destacan en la muestra.

Comparativa top100

En top100 por ranking dominan Solo / Solitaire Game, Hand Management y Variable Player Powers.

En top100 por interés destacan Hand Management, Variable Player Powers, Set Collection y Card Game.

La diferencia entre ambos subconjuntos sugiere que popularidad pública y ranking crítico no siempre coinciden.

Verificación de hipótesis

Hipótesis 1: confirmada. Los datos muestran una clara concentración en juegos de 2 a 4 jugadores y con tiempos de partida típicamente bajos o moderados.






Hipótesis 2: parcialmente confirmada. La relación entre valoración, complejidad y duración es positiva, pero no absoluta.

Hipótesis 3: confirmada. El ranking y la métrica de interés no coinciden exactamente y capturan dimensiones diferentes de la popularidad.

Hipótesis 4: confirmada de forma general. La matriz de correlaciones y el pairplot muestran un patrón multivariante consistente.





Distribuciones numéricas

Distribuciones de variables numéricas







Frecuencias globales

Frecuencias globales en el dataset







Top100 por ranking

Top100 por ranking: entidades predominantes



Top100 por interés

Top100 por interés: entidades predominantes



Conclusiones y próximos pasos

El análisis apunta a una colección con juegos mayoritariamente pensados para grupos pequeños, con duraciones moderadas y complejidad baja-moderada.

La comparación entre ranking e interés sugiere que se pueden estudiar nichos de mercado y preferencias de la comunidad con mayor detalle.

Como siguientes pasos conviene incorporar correlaciones, un análisis temporal por año de publicación y, si se desea, modelos predictivos sencillos.

La memoria queda así alineada con una narrativa técnica completa: contexto, hipótesis, limpieza, análisis, visualización y verificación de hallazgos.