

**DADOS, ESTRATEGIA Y DATOS:
EXPLORATORY DATA ANALYSIS (EDA)
SOBRE EL DATASET DE BOARDGAMEGEEK
(BGG)**

PROJECT BREAK I. EQUIPO 14.

Sandra Gusi Martínez & Emilio Garrote Sánchez
Bootcamp Data Science. Marzo 2026

ÍNDICE

1. Introducción

2. Hipótesis


3. Análisis exploratorio

4. Visualizaciones

5. Conclusiones

6. Recomendaciones

7. Referencias



1. INTRODUCCIÓN Y OBJETIVOS

Introducción

La pandemia y los confinamientos de 2020 y 2021 impulsaron la búsqueda de nuevas formas de ocio, destacando tanto el crecimiento de los videojuegos como el auge de los juegos de mesa, que siguen ganando popularidad en un mercado en expansión. Según expertos, este fenómeno se explica porque en una era altamente digital lo analógico ha recuperado valor como experiencia especial, destacando el componente tangible, estético y social de los juegos de mesa, que favorecen la interacción cara a cara. Además, estos juegos se han consolidado como una forma de ocio familiar que permite compartir momentos de disfrute en un entorno más cercano (1).

Dado que el mercado de los juegos de mesa es amplio, diverso y está en constante crecimiento, resulta necesario recurrir a análisis de datos detallados que permitan identificar patrones, tendencias y relaciones relevantes que no son evidentes a simple vista. Este tipo de exploración sistemática facilita la comprensión de las dinámicas del sector y aporta una base objetiva para el estudio de la popularidad, las dinámicas y las preferencias de la comunidad.

En este contexto, resulta especialmente relevante realizar un análisis exploratorio de datos utilizando la base de datos de [BoardGameGeek](#), ya que esta plataforma concentra información detallada y estandarizada sobre miles de juegos, incluyendo valoraciones, características y preferencias de la comunidad. De este modo, el EDA permite transformar un fenómeno cultural en datos analizables, facilitando la identificación de patrones, tendencias y factores asociados a la popularidad y recepción de los juegos de mesa.

Desde el punto de vista del ecosistema digital, BGG se ha consolidado como una referencia central para la comunidad de juegos de mesa. La plataforma fue lanzada en enero de 2000 por Scott Alden y Derk Solko, y combina base de datos, foros y sistema de valoración colaborativa. En la actualidad, su catálogo incluye más de 150.000 títulos y concentra una comunidad activa de gran tamaño (2), lo que la convierte en una infraestructura de datos especialmente útil para estudios descriptivos y comparativos de diseño lúdico.

El valor analítico de BGG no está solo en el volumen de datos, sino en la estructura relacional de su información: juegos, diseñadores, artistas, editoriales, mecánicas y categorías se encuentran enlazados y permiten análisis multicapas. Además, su sistema de puntuación y ranking facilita comparar recepción crítica y popularidad relativa entre títulos, lo que justifica su uso como fuente principal en esta memoria técnica.

Objetivos

Se definen los siguientes objetivos para este proyecto:

1. Describir la colección de juegos: distribuciones de jugadores, edad mínima, duración de partida y complejidad ('weight').
2. Identificar categorías, mecánicas, diseñadores y artistas más frecuentes en la muestra.
3. Contrastar las listas de 'top' juegos según 'rank_boardgame' y según una métrica de interés (suma de 'owned' + 'wishing').
4. Generar visualizaciones reproducibles y un conjunto de tablas de apoyo para investigación o diseño de juegos.

2. HIPÓTESIS

Antes de iniciar el análisis se plantearon las siguientes hipótesis:

1. La mayor parte de los juegos del dataset estará diseñada para grupos pequeños, especialmente entre 2 y 4 jugadores, lo que influirá en que las duraciones medias de las partidas sean cortas o moderadas. A partir de la frecuencia y valoración de estas características, se plantea la hipótesis de que **determinadas configuraciones de número de jugadores y duración ofrecerán mejores valoraciones y niveles de popularidad que otras.**
2. **La complejidad afecta a la popularidad.** Los juegos mejor valorados tenderán a presentar una complejidad mayor ('weight') y una duración más larga que el promedio.
3. **La popularidad** ('interest'), medida por el sumatorio de las columnas 'owned', 'wishing' y 'wanting', **y la frecuencia de las mecánicas y categorías no será la misma para todos los juegos registrados.** Esto supone que habrá ciertos tipos de mecánicas de juego y categorías temáticas mejor valorados entre el público y que potencialmente pueden existir artistas y diseñadores respectivamente mejor valorados para cada tipo
4. **La edad mínima de los jugadores afectará a la popularidad de los juegos,** ya que determina en parte la complejidad de los mismos.

Como se ha mencionado anteriormente, BGG es una fuente extensa de metadatos sobre juegos de mesa: características de los juegos, valoraciones, número de propietarios ('owned'), listas de deseos ('wishing'), autores, artistas, mecánicas, categorías y rankings. El proyecto Tabletop-games-EDA organiza estos datos y aplica técnicas de EDA para extraer patrones relevantes.

3. ANÁLISIS EXPLORATORIO

Previamente, los datos en bruto extraídos del dataset fueron sometidos a un preprocesado y limpieza, para eliminar los datos incompletos o irrelevantes para el objeto de estudio, de forma que los patrones en los datos pudieran encontrarse de manera más sencilla al eliminar el ruido de fondo. Este proceso consistió en:

- Lectura y revisión de cardinalidad y nulos para decidir columnas a usar.

- Conversión de tipos: por ejemplo, 'rank_boardgame' se convierte a numérico con coerción de errores.
- Eliminación/filtrado de valores no informativos: p. ej. filas con artistas o diseñadores '(Uncredited)' se excluyen de ciertos análisis o columnas con datos no útiles para el estudio como 'family' o 'trading'.
- Tratamiento de nulos: imputación mínima o exclusión según el contexto de la variable y la visualización.
- Creación de variables derivadas: 'interest = owned + wishing' para medir popularidad/atracción. Esta tabla supone un resumen de la situación actual de los juegos según el público.
- Uniones por 'row_id' entre tablas auxiliares (diseñadores, mecánicas, categorías, artistas) para agregar y cruzar información.
- Para determinados análisis, las tablas debieron prepararse realizando un desglose de sus valores. Éstos solían contener la información en forma de listas que fue necesario dividir con el método 'explode()' de la librería de Python pandas.

Esta aproximación de análisis fue además aplicada a tres versiones del dataset, ya que se consideró importante evaluar los resultados tanto a nivel general de los datos como a un subconjunto de datos basados en el interés/popularidad de los juegos y su posición en el ranking. De esta forma, los análisis se aplicaron a:

1. La tabla original solo filtrada por las condiciones del preprocesado.
2. La tabla del top 100 de juegos ordenados en base a su posición en el ranking de la BGG.
3. La tabla con el top 100 de juegos ordenados de mayor a menor valor para su columna 'interest'. Estos juegos serán los de mayor popularidad, ya que tienen en cuenta las que lo tienen guardado en su lista de deseados y las que ya lo tienen.

Análisis univariante

Se aplicó el análisis univariante a las diferentes variables de menor cardinalidad con el fin de sacar conclusiones en base a las frecuencias y a los valores descriptivos (como la media, mediana o moda) de los mismos.

De esta aproximación se observa que:

- Las tendencias relevantes al **número de jugadores (Figura 1 y Figura 2)** muestran que casi todos los valores para el mínimo de jugadores se establecen cerca de 2 y para el máximo de jugadores cerca de 4.
- La **edad mínima (Figura 3)** más frecuente es de 8 años. Sin embargo, se observa una franja de edad en la que se encuentra el mayor número de registros, siendo entre 8 y 14 años. El 50% de los datos se encuentra por debajo de los 10 años.
- La **complejidad (weight)** presenta una frecuencia superior en torno a valores bajos (entre 1 y 2 puntos sobre un total de 5), siendo el valor más repetido 1 y situándose el 50% de

los datos por debajo de los dos puntos (**Figura 3**). Esto supone que la mayor parte de los juegos se encuentran clasificados por debajo de la mitad de la dificultad máxima registrada.

- Para las **categorías**, se observa que “card game” aparece como la más frecuente tanto en la tabla completa como en el top 100 según los valores de interés calculados. También cabe destacar que entre los tres mayores valores de frecuencia para los tres conjuntos de datos de partida, siempre se encuentran también las categorías de “economic” y “fantasy” (**Figura 4 y Figura 5**).
- En el caso de las **mecánicas**, “hand management” se encuentra siempre en el top 2 de las tres aproximaciones de datos contempladas. “Variable player Powers” se encuentra también entre las tres posiciones más altas en los rankings basados en el interés y en los mejor valorados según BGG (**Figura 4 y Figura 5**).
- Tanto para los **diseñadores** como **artistas** más frecuentes se observa que varios nombres se repiten en top 15 en base a la frecuencia aplicado a las tres aproximaciones de datos (**Figura 4 y Figura 5**). Ejemplos de ello son: Reiner Knizia, Paul Dennen, Uwe Rosenberg, Franz Vohwinkel, Vincent Dutrait, Dennis Lohausen...

Análisis bivalente

Previa exploración particular de cada combinación de datos y dado que éstos no cumplían las condiciones de distribución normal, se aplicó el coeficiente de Spearman a las distintas parejas de variables numéricas a fin de registrar correlaciones subyacentes (**Figura 6**). A pesar de que los valores del coeficiente no son muy altos para la mayoría de casos, se observaron algunas relaciones resaltables:

- La **complejidad y el tiempo de juego** presentan una relación directa positiva fuerte (Spearman = 0.7). Esto indica que a mayor complejidad, mayor tiempo de juego.
- La **complejidad** también se relaciona positivamente con la **valoración media** (Spearman = 0.58), lo que muestra que las valoraciones positivas aumentan ante mayores niveles de dificultad.
- La **edad mínima** se correlaciona positivamente con el **tiempo de juego** (Spearman = 0.47). A mayor tiempo de juego, mayor edad mínima se establece para los jugadores.
- El **mínimo de jugadores** y la **valoración media** se relacionan débilmente de manera negativa (Spearman = -0.31). Esto supone que los valores mayores de valoración se dan con menores valores mínimos de jugadores y viceversa.

Una vez revisadas las correlaciones, se plantean diferentes combinaciones a analizar entre los distintos tipos de datos:

- **Número de juegos publicados a lo largo del tiempo (Figura 7)**: Se observa que el número de juegos publicados ha ido en aumento.

- **Complejidad a lo largo del tiempo (Figura 8):** Se observa que los juegos desde los años 2000 han tendido a elevar su complejidad.
- **Rating de los juegos respecto al mínimo de edad (Figura 9):** La edad que presenta mejores valoraciones asociadas serían los 14 años, pero la que presenta una menor dispersión de los datos y un menor número de outliers son los 11 años, por lo que la robustez de esta distribución de datos es mayor para esta edad.
- **Rating con respecto al número máximo y mínimo de jugadores (Figura 10):** Las edades con mayor mediana para los valores de rating se dan en juegos con un mínimo de 2 jugadores y un máximo de hasta 4.
- **Artistas y diseñadores con mayor rating medio por categoría y mecánica (Figura 13 y Figura 14):** Una vez determinadas las categorías y mecánicas más frecuentes en el análisis univariante, se analiza qué artistas y diseñadores presentan una mejor valoración entre todos los juegos que han publicado dentro de las categorías y la mecánica de mayor frecuencia.

Análisis multivariante

Para encontrar tendencias generales, se aplicó el análisis multivariante a las siguientes combinaciones de datos:

- **Tiempo de juego, categoría de rating y complejidad (Figura 11):** Los menores valores de dificultad se encuentran mayoritariamente en juegos con tiempos de juego menores. Las valoraciones intermedias (según la categoría de rating, calculada de 0 a 10), se encuentran asociadas a complejidades menores, mientras que valores más altos de valoración se registran a partir de dificultades superiores a 3 en todos los tiempos de juego. A partir de los 100 mins de duración por partida, la dispersión aumenta.
- **Máximo-mínimo de jugadores y categoría de rating (Figura 12):** Las mejores categorías de valoración se registran en juegos complejos (con una complejidad o weight superior a 3.5 puntos) con un mínimo de jugadores entre uno y tres y un máximo de jugadores cerca de seis. Sin embargo, la densidad de puntos es mayor en valores más bajos de complejidad, asociados a categorías de valoración intermedias (entre 4 y 6 puntos).

4. VISUALIZACIONES




Figura 1: Frecuencia en base al número mínimo de jugadores.




Figura 2: Frecuencia en base al número máximo de jugadores.

Variable	Media	Moda	Mediana
min_players	1.940.726	2.0	20.000
max_players	4.738.831	4.0	40.000
minimum_age	9.837.480	8.0	100.000
weight	1.981.049	1.0	19.259

Figura 3: Tabla con los valores de media, moda y mediana para las variables de mínimo de jugadores (min_players), máximo de jugadores (max_players), edad mínima del jugador (minimum_age) y complejidad (weight).

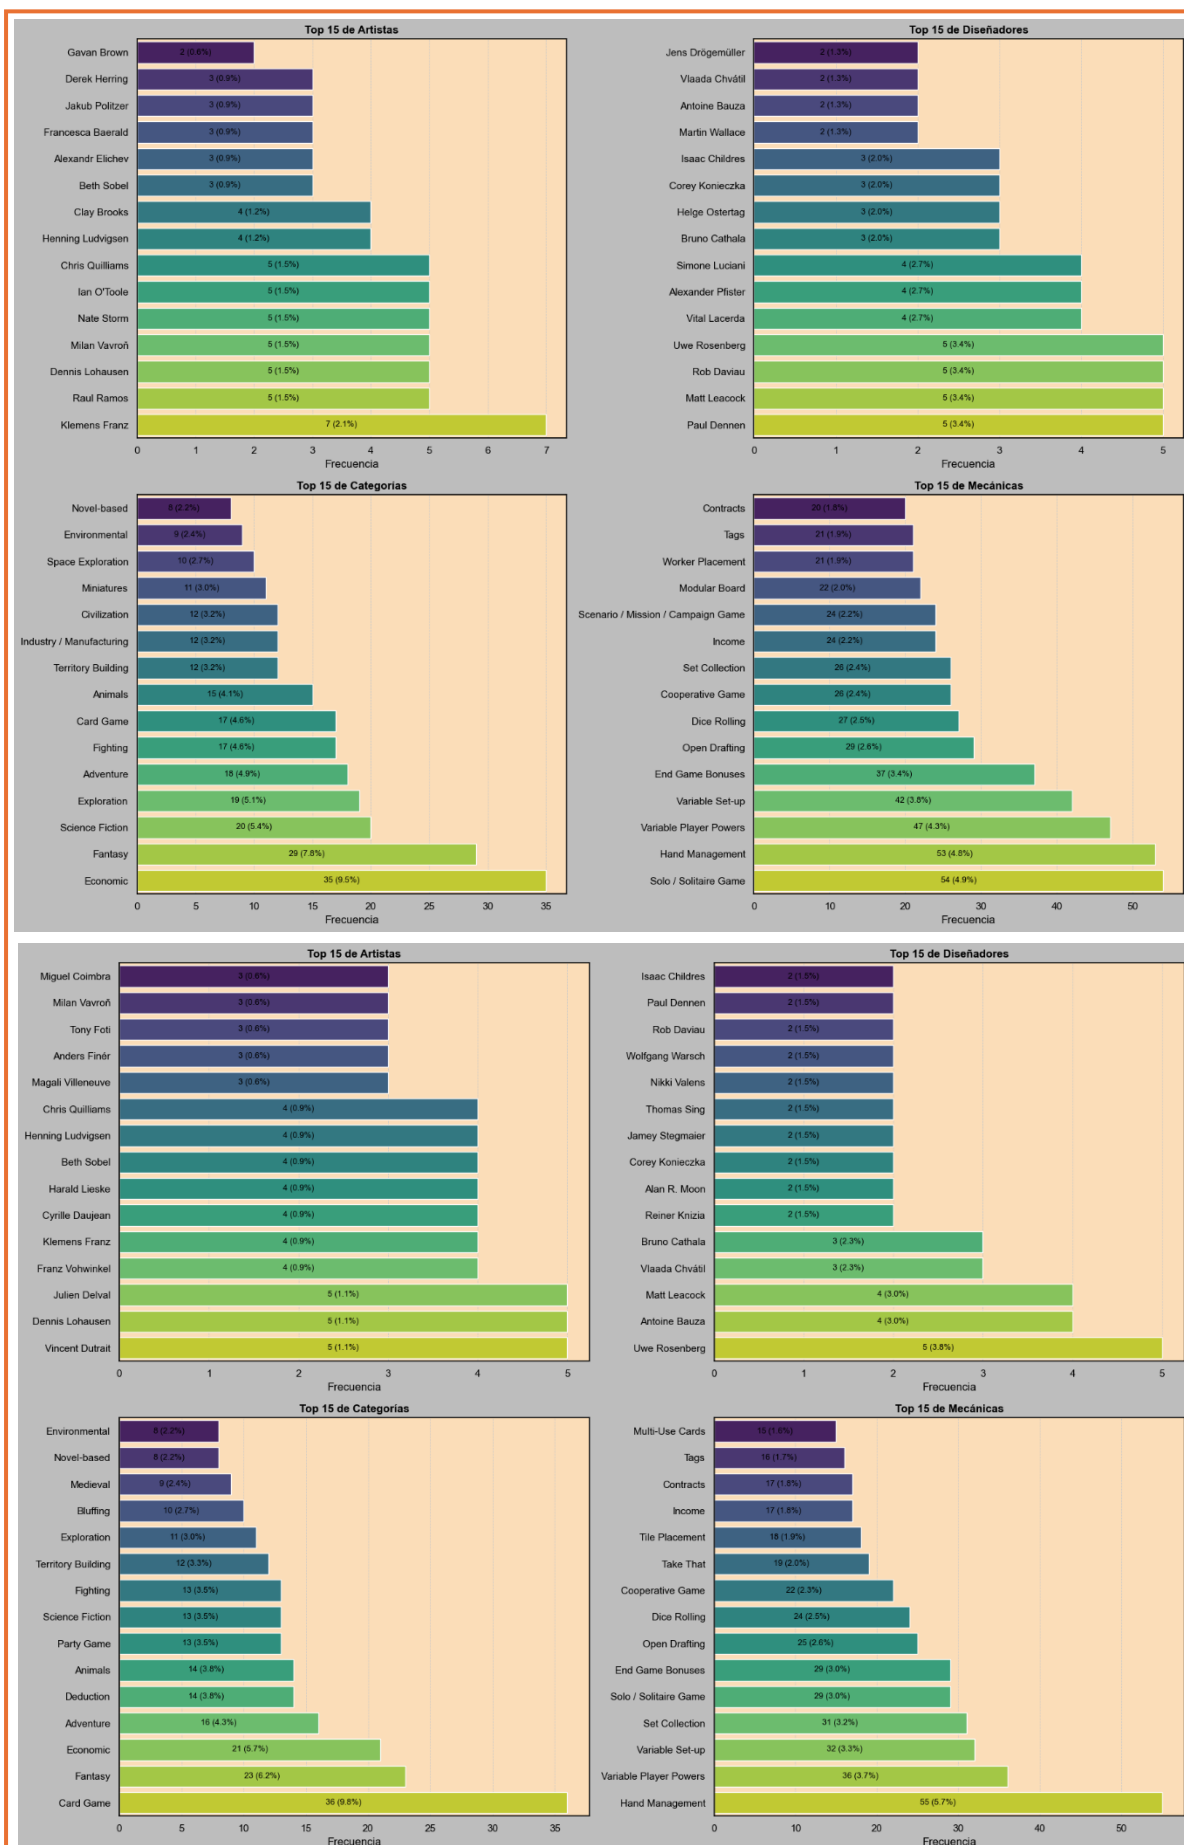


Figura 4: Top 15 categorías, mecánicas, artistas y diseñadores en base a al top 100 de ranking de juegos (arriba) y al top 100 de juegos con mayor interés/popularidad (abajo).




Figura 5: Top 15 categorías, mecánicas, artistas y diseñadores en base a la totalidad de juegos del dataset.




Figura 6: Heatmap mostrando los valores del índice de correlación de Spearman para las variables valoración media (average_rating), complejidad (weight), tiempo de juego (playingtime), mínimo y máximo de jugadores (min_players y max_players), edad mínima (minimum_age) e interés/popularidad (interest).




Figura 7: Número de juegos base y expansiones publicados a lo largo del tiempo desde el año 2000.






Figura 8: Evolución de la complejidad a lo largo del tiempo.






Figura 11: Pair plot mostrando la distribución de los juegos en base a su tiempo de juego en minutos (eje Y) y dificultad (eje X). Los puntos se encuentran coloreados en base a la categoría de valoración.




Figura 12: Pair plots mostrando la distribución de los juegos en base a su máximo (derecha) o mínimo (izquierda) de jugadores (eje Y) y dificultad (eje X). Los puntos se encuentran coloreados en base a la categoría de valoración.

Mecánica	Diseñador (mayor bayes average)	Bayes Average	Diseñador (más frecuente)	Nº juegos (BGG ID)
Dice Rolling	Ananda Gupta	8,04086	Jim Dunnigan	84
Hand Management	Ananda Gupta	8,04086	Reiner Knizia	140
Set Collection	Andy Clautice	7,93731	Reiner Knizia	124
Variable Player Powers	Mathias Wigge	8,35456	Steve Jackson (I)	48

Figura 13: Tabla mostrando los mejores diseñadores en base al bayes average o en base al número de juegos publicados para las mecánicas más frecuentes.

Categoría	Artista (mayor bayes average)	Bayes Average	Artista (más frecuente)	Nº juegos (BGG ID)
Animals	Steffen Bieker	8,35456	Oliver Freudenreich	25
Dice	Jakub Dzikowski	8,4769	Oliver Freudenreich	25
Fantasy	Lucile Mathieu	8,29747	Franz Vohwinkel	38
Science Fiction	Derek Herring	8,23575	Henning Ludvigsen	27

Figura 14: Tabla mostrando los mejores artistas en base al bayes average o en base al número de juegos publicados para las categorías más frecuentes.

5. CONCLUSIONES

El análisis conjunto de los datos permite observar, en primer lugar, una evolución creciente en el número de juegos publicados a lo largo del tiempo, lo que evidencia la expansión sostenida del mercado de juegos de mesa. Paralelamente, se aprecia una tendencia al aumento de la complejidad desde los años 2000, indicando una diversificación hacia experiencias más estratégicas y elaboradas, sin abandonar los juegos ligeros predominantes en la distribución general.

En relación con las variables de valoración, se observa que la edad mínima de 14 años presenta las mejores valoraciones medias, aunque la edad de 11 años muestra una distribución más estable, con menor dispersión y menos valores atípicos, lo que sugiere una mayor robustez en términos de consistencia de valoración. Asimismo, los juegos con configuraciones de 2 a 4 jugadores concentran las medianas más altas de rating, reforzando la idea de que los formatos para grupos reducidos son los mejor valorados por la comunidad.

En cuanto al análisis temático y de autoría, una vez identificadas las categorías y mecánicas más frecuentes —destacando especialmente ‘card game’, ‘economic’ y ‘fantasy’ en el caso de las categorías, y ‘hand management’ junto con variable ‘player powers’ en el caso de las mecánicas— se observa que ciertos diseñadores y artistas obtienen mejores valoraciones medias dentro de estos subconjuntos. Esto permite relacionar la alta presencia de estos elementos con la calidad percibida de los juegos, sugiriendo que no solo existen patrones

dominantes en el diseño y la temática, sino también una concentración de autores que sobresalen en términos de recepción positiva dentro de los segmentos más representativos del dataset.

6. RECOMENDACIONES

Con el objetivo de definir directrices orientativas para el diseño y la comercialización de juegos de mesa en el contexto actual del mercado, se recomienda:

- Desarrollar juegos dentro de unos valores medio de dificultad, no superando los 100 minutos de duración por partida aproximadamente.
- Las categorías de fantasía, juego de cartas y económico son las más recomendables para asegurar una buena acogida del público. Incluir mecánicas de juego como poderes variables por jugador y manejo de mano también es recomendable para llegar a una mayor parte del mercado.
- Establecer un rango de entre 2 y 4 jugadores puede ser beneficioso para atraer la atención del público, así como mantener una edad mínima aproximada para los jugadores de 10-11 años. Esto asegurará una complejidad media al mismo tiempo que situaría al juego dentro del rango de los potencialmente mejor valorables, dada la distribución observada de los datos.
- Dadas las categorías y mecánicas más destacables, se recomienda contratar a artistas como Franz Vohwinkel y Lucile Mathieu y a diseñadores como Reine Knizia para desarrollar el juego, ya que destacan por su valoración en los juegos publicados dentro de estas características.

7. REFERENCIAS

1. Zambrana, M., & Sánchez-Juárez, A. (2025). *Juegos de mesa: por qué el ocio analógico triunfa en la era digital*. Universitat Oberta de Catalunya.
<https://www.uoc.edu/es/news/2025/juegos-de-mesa-por-que-ocio-analogico-triunfa-en-era-digital>
2. BoardGameGeek. (s. f.). *Welcome to BoardGameGeek*.
https://boardgamegeek.com/wiki/page/Welcome_to_BoardGameGeek